

RealComm

真实通信信道下的音频伪造检测与适配

Li Wang*, Jindong Wang*, Wan Lin*, Kunyu Feng*, Lei Wang, Rizhao Cai, Ce Fang, Jinzhe Xue, Jie Shi, Haizhou Li, Zhizheng Wu

*Li Wang、Jindong Wang、Wan Lin 与 Kunyu Feng 为共同第一作者。Lei Wang、Rizhao Cai、Ce Fang、Jinzhe Xue、Jie Shi 署名华为；其余作者署名香港中文大学（深圳）。

摘要

真实通话中的声学采集、设备处理与传输编码会共同改变语音信号，可能影响音频伪造检测器的可靠性。为系统评估这些影响，本文构建 RealComm，将数字语音与经过真实手机通话的同源录音配对。采集设计覆盖声学、有线注入、手持与免提通话模式，以及拨出方降噪设置，真实与伪造语音采用相同录制条件。数据集包含用于评测的 RealCommBench 和用于适配训练的 RealCommTrain。进一步提出 RealComm-Aug，通过分阶段波形扰动模拟采集与传输过程，并研究其与真实通话训练的结合。已有检测器的实验表明，即使在数字域表现较好的模型，经过通话后也出现明显退化，声学注入尤其困难。配对的质量与频谱分析发现，在受测模型上，录制条件层面的质量退化与检测困难一致相关，而高频衰减本身不足以解释检测难度。模拟增强与实录训练具有互补作用，联合适配取得三个受测模型最低的通话域错误率，其中 Teffic-Audio 的 EER 由 37.94% 降至 22.37%。

Demo 与 Benchmark 访问说明统一见 GitHub 项目主页 (<https://github.com/AmphionTeam/RealComm>)。

关键词：音频伪造检测；真实通话；域偏移；数据增强；实录适配。

1. 引言

音频深度伪造（audio deepfake）是利用机器学习合成或操纵的语音，文本转语音和语音转换是其中的典型技术[1]。近年来，语音生成系统已能根据文本和短参考录音生成自然、接近目标说话人声音的语音[2, 3, 4]。这些能力也可能被用于身份冒用和语音诈骗。音频伪造检测通过区分真实语音与人工生成或操纵的语音应对这一风险，相关任务与方法可参见 Yi 等人的综述[1]。

真实通话的信号处理链路比直接评测数字语音更复杂。语音可能先经过扬声器播放与麦克风采集，再受到设备处理、降噪和传输编码的共同影响。这些过程可能改变检测器依赖的时频线索，导致性能下降[5]。因此，仅评测数字源文件，还不能回答检测器在接听方实际收到的语音上表现如何。

为研究这一差异，我们构建了数字语音与真实通话录音逐源配对的 RealComm。采集覆盖声学、有线注入、手持与免提模式、多种拨出方与接听方设备组合，以及智能手机的用户可控降噪功能。真实与伪造语音经过相同录制条件；通话前后使用同一条源语音，固定文本、说话人与生成系统。RealCommBench 用于比较不同条件下的检测表现，RealCommTrain 用于适配训练，同源语音的所有版本始终保留在同一划分。

已有检测器在真实通话后均出现明显退化。分条件评测发现，声学注入尤其困难，降噪的影响则随检测器和输入配置变化。进一步结合质量与频谱分析可以看到，受测模型的质量退化与检测退化呈一致正相关，而高频衰减本身不足以解释不同条件的检测难度。这些结果表明，适配需要考虑通话链路中多个阶段的共同作用。

为缓解这一偏移，我们提出 RealComm-Aug，并研究其与真实通话训练的结合。RealComm-Aug 按信号路径组织声学、设备、编解码与传输扰动，通过中间输出保留常见的加噪、混响和文件压缩增强，不要求每条语音都经过模拟通话。该流程作用于模型输入波形，可与已有检测器结合，并保留其模型内部增强。在相同初始检测模型上，我们比较模拟增强、RealCommTrain 训练及二者结合；联合适配取得三个受测模型最低的整体通话域错误率。

本文的贡献包括：

- 构建配对的真实通话测试集与适配训练集，覆盖注入方式、设备组合、手持/免提模式和降噪状态。
- 评测已有检测器，结合采集条件、语音质量与频谱变化分析检测退化。
- 提出分阶段增强流程，并在三个模型上比较模拟增强、实录训练及联合适配。

2. 相关工作

2.1 数据集与泛化评测

ASVspoof 系列逐步覆盖合成、转换、重放、传输压缩和更丰富的攻击条件[6, 7, 8, 9]。WaveFake、MLAAD 和 Codecfake 分别扩展生成器、语言和神经编码语音的覆盖[10, 11, 12]；野外语音评测关注跨数据集泛化，SpoofCeleb 将多样的真实来源条件纳入生成与检测评测[13, 14]。泛化也是 Yi 等人综述中的重要主题[1]。RealComm 通过同源数字语音与真实通话录音的配对，为这些评测维度提供补充。固定源语音后，可以比较不同采集条件下的检测表现。

2.2 信道影响与真实通信

已有研究通过信道失配、噪声、信号处理和压缩实验，分析检测器对不同扰动的响应[5, 15]。ADD-C 研究编解码、模拟丢包及通信增强，RTCFake 覆盖实时通信平台；电话、Telegram 通话和访谈场景的研究也展示了混合原始与退化语音进行适配的价值[16, 17, 18]。我们此前的 RealComm 工作同样关注真实通信信道下的检测评测[19]。当前采集设计将注入路径、设备路由、通话模式和降噪状态结合起来。配对录音使这些条件能够与检测结果、语音质量和适配效果联系起来分析。

2.3 检测表征

RawNet2 和 AASIST 从波形或时频结构学习鉴伪特征[20, 21]。另一类方法利用 wav2vec 2.0、HuBERT、XLS-R、WavLM、Whisper 及 W2v-BERT 2.0 等预训练表征，并结合鉴伪分类头及任务训练[22, 23, 24, 25, 26, 27]。自监督表征与增强结合、有效层选择等方法也用于检测[28, 29]，本文同时纳入已有发布模型 DF Arena[30]。本文在统一的配对协议下比较完整检测系统。结果共同反映模型结构、预训练和鉴伪训练设置的作用。

2.4 数据增强与质量诊断

RawBoost 和信道增强研究利用卷积、噪声与压缩扰动扩展训练分布[31, 32]，EnCodec 等神经音频编码方法提供了进一步的训练变换[33]。这些方法与真实信道适配研究共同支持对模拟增强、实录训练及其组合的比较[18]。

RealComm 在配对评测中结合增强研究与语音质量诊断。RealComm-Aug 沿采集和通信路径组织已有类型的变换，并评估其单独使用及与实录训练结合的效果。内容准确性和说话人相似度沿用 Seed-TTS Eval，音质


采用 DNSMOS P.835 OVRL[2, 34, 35]。这些指标描述语音质量的不同方面，本文进一步分析其变化与检测退化的关系。

3. RealComm 数据集


3.1 真实通话采集与条件

数字域源语音进入拨出方（Caller）手机，由拨出方发起通话；接听方（Receiver）使用通话 APP 的录音功能保存收到的语音。每条通话录音均可关联到对应的数字域源语音。图 1 给出采集链路和设备划分。

(a) Real mobile-call acquisition



(b) Train / development



(c) Test




图 1. RealComm 采集链路及设备划分。上方为三种注入配置、真实通话和接听方内录；下方为训练/开发与测试设备环，底部回边闭合设备环，各连接均双向录制。Samsung—iPhone 配对为两环共有；Oppo 仅出现在训练/开发，Vivo 仅出现在测试。通话模式和降噪设置均指拨出方。

输入配置。 Over-the-air (OtA) 使用外部扬声器播放源语音，经空气进入拨出方麦克风，分别采集 Handset 和 Speakerphone 两种通话模式。Line-to-microphone (LtM) 通过线缆将语音接入麦克风输入，跳过额外的空气传播。因此，测试包含 OtA-Handset、OtA-Speakerphone 和 LtM 三种配置。Handset 表示听筒通话模式，不额外假定录制者的持机姿势。

OtA 使用 Huawei Sound X 播放，扬声器与拨出方手机处于同一水平面，距地面约 1 m；参考音量约 60%，间距约 30 cm，并按实际采集情况调整播放音量和间距，以保证录制清晰。LtM 通过手机的有线耳机麦克风输入传入信号。

设备路由。 每条路由按提供源语音的拨出方指向录音的接听方来定义，交换两端角色即构成另一条路由。

训练/开发采用 Mate70 Pro—iPhone—Samsung—Oppo—Mate70 Pro 双向环；测试采用 Mate70 Pro—Samsung—iPhone—Vivo—Mate70 Pro 双向环。每个环包含 8 条有向路由。相比四台设备的 12 条全连接有向路由，这一设计减少采集量，同时保留每台设备作为拨出方和接听方、分别与两个相邻设备通信的覆盖。

降噪设置。 智能手机降噪在抑制背景噪声的同时，可能改变鉴伪模型依赖的信号特征，因此需要配对比较开启与关闭时的检测表现。8 条路由与 3 种输入配置形成 24 个基础条件。对于支持用户控制降噪开关的配置，补充 on 状态录制：训练侧增加 20 个条件，测试侧增加 18 个条件，分别得到 44 和 42 个条件。off、on 和 unavailable 单独保留；unavailable 表示该配置无可控开关，不能并入 off。off 也不代表手机内部的全部语音处理都被关闭。设备型号、录制时系统版本和各配置的降噪支持情况见表 1。

表 1. 设备与拨出方降噪控制。 系统版本为录制时版本。H：OtA 手持；S：OtA 免提；L：LtM。Yes：已有 off/on 配对录音；NA：该录制配置无用户可控开关。

OS	Denoising	H	S	L
Huawei Mate70 Pro (Mate70 Pro)				
HarmonyOS 6.1.0.135 SP8	Call noise reduction	Yes	Yes	Yes
iPhone 15 Pro (iPhone)				
iOS 26.6.1	Voice Isolation	Yes	Yes	Yes
Samsung Galaxy S25+ (Samsung)				
Android 16	Voice focus	Yes	Yes	NA
Oppo Find X9 (Oppo)				
ColorOS 16.0.1	Clear Voice	Yes	Yes	NA
Vivo X300 Pro (Vivo)				
OriginOS 6	Voice Isolation	NA	Yes	NA

3.2 源语音与数据划分

DigitalPool 包含 2,800 条语音，真实/伪造、中英文均衡。真实语音、目标文本和参考 prompt 来自 Seed-TTS Eval；伪造语音由 CosyVoice2、F5-TTS、FlexiVoice、IndexTTS2、MaskGCT、Vevo2 和 Minimax 生成，每种生成器 200 条[34, 3, 4, 36, 37, 38, 39, 40]。样本经过内容准确性和音质筛选，检测器分数不参与筛选。因此，本研究使用的是质量筛选后的源语音队列。

划分前，先按内容和参考音频等关联身份分组。第一层按 8:2 将 2,240 条源语音分配到训练侧，560 条保留测试；训练侧再按 8:2 分为 1,792 条 train 和 448 条 dev。两级划分兼顾训练规模与独立评测容量。数字版本和所有同源通话版本始终属于同一划分。

表 2. 源语音划分与真实通话录音规模。

划分	数字域源语音	参与实录的源语音	每源条件数	通话录音
Train	1,792	224	44	9,856
Dev	448	56	44	2,464
Test	560	560	42	23,520

RealCommTrain 由 train 和 dev 的 12,320 条实录组成，RealCommBench 包含全部 23,520 条测试实录。训练侧选择较少源语音进行多条件录制，以控制采集成本；数字训练池仍完整保留。录音条数包含同一源语音的不同条件版本，不等同于独立内容数量。

训练与测试覆盖相同的七个生成器，本文主要研究未见内容与通信路径上的泛化，不将其解释为未见生成器测试。

3.3 统一测试集与分析维度

所有 23,520 条通话录音组成一个完整测试集，整体结果直接由全部分数计算。输入配置、降噪和设备路由是这个测试集的分析标签，不另设多个主测试集。三种输入配置分别包含 7,840、8,960 和 6,720 条录音，数量差异来自降噪开关的可用情况。

适配分析中的路由分组以 RealCommTrain 为参照：Samsung ↔ iPhone 为已覆盖路由，Mate70 Pro ↔ Samsung 为已见设备的新组合，另两组分别为测试专用 Vivo 作为拨出方和接听方。这种“已见”不代表零样本模型见过 RealComm 通话。由于各组的配置和降噪组成不同，组间差异不单独归因于手机硬件。

4. 统一实验设置

4.1 模型与输入协议

正文零样本分析包含 WavLM-L (Teffic)、Whisper (Teffic)、AASIST (Teffic)、Teffic-Audio 和 DF Arena 500M V1 五个已有检测器。后文分别简称为 WavLM-L、Whisper、AASIST、Teffic-Audio 和 DF Arena。Teffic-Audio 采用 W2v-BERT 2.0 编码器及句级聚合、分类头。F 表示使用已有权重，不进行 RealComm 参数更新。后续训练覆盖 WavLM-L、AASIST 和 Teffic-Audio。初步评测还包含 XLSR-SLS，其数字域/通话域 EER 为 38.57%/50.31%；由于数字域基线已较弱，难以充分解释新增通话过程的影响，故未纳入正文图表与主要比较。

每个模型评测同一份 24,080 文件清单：560 条数字测试语音与 23,520 条同源通话录音。音频统一为 16 kHz 单声道。WavLM-L、Whisper 和 Teffic-Audio 读取前 64,600 个采样点，较短语音保留原长度；AASIST 和 DF Arena 读取前 64,000 点，再按其接口要求循环补齐到 64,600 点。每文件推理一次，不使用滑窗平均。同一模型的数字/通话及适配前后比较保持输入规则一致。

每条音频保存鉴伪分数与同一次推理的 embedding，统一为分数越大越像伪造。embedding 记录提取层及池化规则，不额外归一化。当前正文以检测分数为主，embedding 留作后续模型内诊断，不用于选择测试样本。

4.2 指标与配对比较

主要指标为 EER (%)，通话域 EER 减数字域 EER 得到 ΔEER ，单位为百分点。整体 EER 由完整分数集合计算，不对分组 EER 求平均。生成器分析使用该生成器的伪造语音和同一数据域的真实语音作为参照。

输入方式比较补充同源、同路由和共同降噪标签的匹配分析。降噪 off/on 使用 10,080 组同源、同路由、同配置的配对录音；3,360 条 unavailable 录音保留在整体结果中，不进入开关比较。已有不确定性分析在 148 个源关联组上进行 2,000 次配对重采样，正文图表保留简洁的点估计。这些统计描述固定采集条件下的源语音变化，不等同于新设备或多次采集的波动。

适配结果均为单次训练的 checkpoint 结果。EER 显示两位小数，差值用未舍入数值计算，因此直接相减显示值有时相差 0.01 个百分点。

5. 零样本检测结果

5.1 数字域到通话域的整体退化



图 2. 零样本 EER (%，越低越好)。(a) 数字域与通话域，柱顶标注 EER；(b) 三种注入配置；(c) 配对降噪 off/on；(d) 中英文的数字域与通话域；(e、f) 七个生成器在数字域和通话域的结果。柱状图与热图均使用 0–60% 的尺度。生成器 EER 使用该生成器的伪造语音与同一数据域的全部真实语音计算。

受测模型在通话后的 EER 均上升超过 30 个百分点。数字域 EER 为 0–15.71%，通话域达到 37.95–47.88%。例如，WavLM-L 由 4.64% 升至 40.00%，AASIST 由 7.50% 升至 40.19%。两域逐源对应，这一差距不能简单归因于测试时换了一批生成语音。

5.2 注入方式

声学注入比有线注入更难检测。受测模型在 LtM 上的 EER 均低于两类 OtA。WavLM-L 的 LtM EER 为 23.72%，Handset 和 Speakerphone 分别为 41.96% 和 45.33%；Teffic-Audio 对应为 16.46%、41.10% 和

41.70%。匹配共同路由与降噪标签后，LtM 的优势仍然保留。结果将额外的外部播放与麦克风采集路径同更大的检测困难联系起来，但不能分离扬声器、房间、麦克风和内部处理各自的贡献。

手持与免提不存在跨模型一致的优劣关系。 两者的 EER 排序随检测器变化，因此当前更明确的区分是声学注入与有线注入，而不是某一种通话模式普遍更容易检测。

5.3 降噪、语言与生成器

开启降噪后，受测模型的整体 EER 均下降。 图 2 (c) 使用严格配对的 off/on 子集，例如 AASIST 由 42.70% 降至 40.18%。这一方向在受测模型的合并结果上是一致的，但逐路由、逐配置的配对条件仍有改善与回退，不能理解为每个条件都获益。

通话域退化在中英文上均存在。 图 2 (d) 中，受测模型在两种语言上都出现通话后 EER 升高。两种语言的相对难度仍随模型变化：AASIST 的英文 EER 较低，DF Arena 的中文 EER 较低。每种语言包含 280 条数字源语音及 11,760 条通话录音；文本与说话人的差异使这一排序不能直接归因于语言本身。

通话域退化覆盖全部七个生成器。 图 2 (e、f) 中，受测模型对每个生成器均出现通话后 EER 升高，说明问题不局限于一种合成系统。该分析覆盖当前采样的生成器，不代表对未见生成器的泛化评测。

6. 语音质量、频谱变化与检测退化

6.1 同源语音的质量变化

内容准确性和说话人相似度按照 Seed-TTS Eval 的评测器计算[34]。英文 WER 使用 Whisper-large-v3，中文 CER 使用 Paraformer-zh[41]；数字与通话语音分别对照同一份目标文本。这里报告逐句错误率的均值，而不是把全部词或字的错误数合并计算。

Speaker SIM 使用官方 WavLM-large 说话人评测模型。固定生成或源数据中的同一个参考 prompt，分别计算 prompt 与数字语音、prompt 与对应通话语音的 embedding 余弦相似度。真假语音分开报告。SIM 衡量对参考说话人的保持程度，不是通话波形对源波形的保真度。上述评测器与鉴伪分类器分开使用。

整体音质采用 DNSMOS P.835 OVRL，独立评价每条数字语音和通话语音，再做同源比较[35]。它是无参考的整体音质预测，数字语音不作为该模型的输入参考。




图 3. 语音质量均值与条件分层。各指标保留自己的数值尺度：WER/CER 越低越好，SIM 和 DNSMOS 越高越好。SIM 对真假语音分别统计。unavailable 录音计入 Call 整体结果，开关对照仅展示 off/on。

通话后，内容准确性、说话人相似度和预测音质均下降。英文 WER 由 0.71% 升至 10.12%，中文 CER 由 1.19% 升至 7.18%；真实语音 SIM 由 0.747 降至 0.503，伪造语音 SIM 由 0.754 降至 0.537；DNSMOS 由 3.32 降至 2.57。

LtM 的三类质量指标均优于两类 OtA。它的识别错误最低、SIM 和 DNSMOS 最高。DNSMOS 为 3.03，Handset 和 Speakerphone 分别为 2.36 和 2.42，与第 5 节的检测难度排序一致。

降噪对语音质量的影响随输入配置改变。在四条共同路由上，Speakerphone 开启降噪后，WER/CER 平均增加 3.96/3.48 个百分点；LtM 则平均减少 2.72/1.38 个百分点。两类 SIM 也在 Speakerphone 下降、LtM 上升。合并均值会掩盖这些相反变化，结论限于当前比较的录制条件。

6.2 通话后的频谱变化




图 4. 同源频谱变化。上方为归一化平均功率谱密度，深蓝虚线表示 Digital；下方为每 1 kHz 频带的能量占比变化，通话减数字，单位为百分点。两图共用 0–8 kHz 横轴。

在统一的 16 kHz 采样率和分析规则下，每句功率谱先按总功率归一化。通话侧先在同一源内平均同配置录音，再对 560 条源语音等权汇总；在线性域平均后转换为 dB。该图比较频谱形状，而不比较绝对音量。

通话改变了频谱形状，高频末端衰减尤其明显。三种配置在 7.5–8 kHz 附近均出现明显下降。7–8 kHz 能量占比从 Digital 的 0.248%，降为 Handset 的 0.123%、Speakerphone 的 0.058% 和 LtM 的 0.015%。归一化占比描述频谱形状，不表示绝对增益，也不能用于反推通话协商的 codec。

声学注入还改变了语音中频段的能量分布。1–2 kHz 能量占比从 Digital 的 6.81%，降为 Handset 的 1.84% 和 Speakerphone 的 2.25%，LtM 则保持在 6.79%。这一频段与承载语音区别信息的部分元音共振峰区域重叠 [42]。因此，OtA 中的相对下降提示，额外的播放与采集路径可能改变语音谱包络及这些线索的相对强度，影响不只发生在高频末端。这是对频谱重新分布的合理推断，并非已经测得共振峰线索丢失。

高频保留程度本身不足以解释检测难度。 LtM 的 7–8 kHz 能量保留最少，却在受测模型上最容易鉴伪。因此，仅凭高频损失无法解释 OtA 与 LtM 的检测性能排序。

6.3 质量与频谱变化是否对应检测退化

每个录制条件都包含相同的 560 条源语音，因此可以将 42 个条件作为 42 组对应观测。计算步骤为：先求各条件相对 Digital 的平均质量变化，再求该条件的 EER 增量，最后跨条件计算 Spearman 相关。WER/CER 使用对应语言的 EER；SIM 和 DNSMOS 使用完整条件集合。统一方向后，识别错误增加、SIM/DNSMOS 下降均表示质量退化；频谱指标使用 4–8 kHz 能量占比下降。




图 5. 42 个录制条件上的 Spearman 相关。正值表示某项变化更大时，检测退化通常也更大。该图统计条件均值之间的关系，不是逐条语音的误判预测，也不是因果效应。

受测模型的质量退化与检测退化呈一致的正相关。 WER、CER、SIM 和 DNSMOS 的退化量与 EER 增量均为正相关，跨模型范围分别为 0.58–0.78、0.65–0.80、0.64–0.81 和 0.72–0.90。质量下降较多的通话条件，通常也更难鉴伪。

这种关联不完全来自 OtA 与 LtM 的差别。 仅比较 LtM 条件，受测模型的 DNSMOS 退化与 EER 增量仍为正相关，系数为 0.54–0.87。同一种输入路径内也存在这一关系，但强度随模型和配置变化。

高频占比变化与检测退化的关联明显较弱。 受测模型的 4–8 kHz 能量占比下降与 EER 增量相关为 -0.22 至 0.11，方向不一致。相比单一的高频指标，当前质量指标更能对应条件间的检测难度。

这些结果描述条件间的关联，不代表因果关系或逐条语音的判断。 质量与检测都可能受到同一处理链路影响；质量评测使用完整语句，鉴伪使用第 4 节的前段输入协议。因此，该分析用于解释条件差异，不用自动质量分数替代鉴伪评测。

7. 模拟增强与真实通话适配

7.1 RealComm-Aug

RealComm-Aug 按声学环境、设备处理、编码与传输的先后关系组织波形扰动。每条输入先选择一个场景，再采样其中的操作和参数；真实与伪造语音共享采样分布，并保留原鉴伪标签。流程允许在环境、设备或文件编码后直接输出，因而同时包含常规加噪、混响等增强与通话路径。图 6 展示处理顺序和分支。




图 6. RealComm-Aug 的阶段与输出路径。上方旁路表示跳过环境传播的 LtM 式直接输入；经环境阶段进入设备与通话阶段对应 OtA 式路径。环境、设备和文件输出提供非通话增强；设备/文件场景可按配置跳过前置阶段。接收端内录后直接送入检测器，不增加外放重录。每次选择一条场景路径，图中分支不同时全部启用。IR 为脉冲响应，EQ 为均衡。

声学环境。 RIRS_NOISES 与 Graphi07 提供房间响应，MUSAN 及高斯噪声提供背景干扰[43]。混响与加噪可独立或共同使用。环境噪声在设备与通信处理之前加入，随语音共同经过后续链路。LtM 式通话输入跳过这段额外的空气传播。

设备响应与处理。 micirp、MADIR 和 POLIPHONE 的设备响应，或平滑 EQ，模拟不同频率响应；采集噪声与环境背景声分开采样。低幅值门控、削波或卷积非线性、电平控制、动态压缩和位深量化提供幅度及处理变化。直接通话路径可包含 EQ，但不额外加入声学麦克风 IR。这些操作覆盖设备影响的类型，不精确复现某一手机。

文件编码与通话传输。 文件分支使用 MP3、AAC 和 Vorbis。通话分支按频带限制、采样率往返转换、语音 codec 及模拟丢包的顺序处理；codec 候选包括 GSM、Opus、Speex、G.711 和 G.723.1。两类编码属于不同输出场景，不默认串联。候选 codec 用于产生训练扰动，不表示实录时使用了相同编码。

模拟丢包与接收输出。 对 20 ms 解码波形帧施加独立或突发掩码，以静音或重复前帧填充，近似丢包的可听结果。这不是实际编码数据包级的网络模拟。接收端输出不再经过扬声器、房间响应或额外加噪。

7.2 训练设置

表 3. F/A/T/A+T 的训练数据与新增波形处理。原数字训练数据指检测器已有训练混合数据，不是 RealCommTrain 的配对数字源子集。

设置	训练数据	数据侧波形处理
F	不更新参数	仅测试预处理
A	原数字训练数据	RealComm-Aug
T	原数字训练数据 + RealCommTrain/train	数字样本保留原增强；通话录音不增加数据侧增强
A+T	与 T 相同	数字样本使用 RealComm-Aug；通话录音不增加数据侧增强

所有适配模型均从对应 F 权重开始；A+T 不从 A 或 T 继续训练。T 与 A+T 加入 9,856 条训练实录，dev 录音不参与训练，也不额外加入 DigitalPool 中的同源数字子集。模型结构和模型对应的训练设置在对比内保持一致。

训练统一采用 16 kHz 单声道和 64,600 采样点长度上限，裁剪与补齐沿用各模型原有规则。数字数据保留每轮每 type 最多 1,000 条的采样方式；T 和 A+T 将 9,856 条实录按 88 个条件×真假 type 加入每轮采样池，不额外过采样实录。优化器和学习率调度沿用各模型原方案。其中，Teffic-Audio 的 A 和 A+T 使用 AdamW、初始学习率 4×10^{-6} 、余弦调度、有效 batch 128，训练 10 轮，按原公开验证流程选模。所有结果均对应单个训练 checkpoint。

既有模型内部的神经 codec 增强保持原训练设置，EnCodec 不是 RealComm-Aug 新增的数据侧模块。通话录音绕过新增数据侧增强，不等于关闭模型内部的所有训练操作。测试时不使用增强。

当前配方中，保留原样、环境输出、设备输出和文件输出的概率分别为 0.20、0.08、0.06 和 0.06；直接通话与声学通话各为 0.30。各阶段内部继续采样，因此场景概率不等于某个操作最终被执行的概率。

8. 适配结果与分析

8.1 整体收益与数字域保持

表 4. 三模型适配 EER (%)。各模型、各数据域内的最优结果加粗。

模型	数据域	F	A	T	A+T
WavLM-L	Digital	4.64	4.29	3.21	3.21
WavLM-L	Call	40.00	38.71	35.48	34.16
AASIST	Digital	7.50	8.93	6.07	8.21
AASIST	Call	40.19	38.49	37.96	36.90
Teffic-Audio	Digital	0.00	0.36	0.36	0.00
Teffic-Audio	Call	37.94	34.92	23.84	22.37

注：Teffic-Audio 适配对照使用同一 F 权重的 FP32 重测，Call EER 为 37.94%；图 2（a）沿用冻结零样本结果 37.95%。两条记录及其推理口径分别保留。

实录训练的收益大于单独模拟增强。 A 使 WavLM-L、AASIST 和 Teffic-Audio 的通话 EER 分别下降 1.29、1.69 和 3.02 个百分点；T 的降幅更大，分别为 4.52、2.23 和 14.11 个百分点。模拟增强有效，但当前实验中不能代替实录训练。

模拟增强与实录结合取得最低的整体通话 EER。 A+T 在三个模型上均最佳，相对 T 进一步改善 1.33、1.06 和 1.46 个百分点。这说明在有真实通话数据时，保留模拟扰动仍有补充价值。

通话域收益可能伴随数字域损失。 AASIST 从 T 的 6.07% 升至 A+T 的 8.21%，存在数字域与通话域之间的权衡。

8.2 输入配置与降噪




图 7. T 减 A+T 的 EER 差值，单位为百分点。青色正值表示改善，橙色负值表示回退。左侧标明五个分析维度：注入配置（Handset、Speakerphone、LtM）、降噪状态、设备路由、语言和 DNSMOS 质量下降层级。每个维度内比较对应子集，分组不使用检测分数。

WavLM-L 与 Teffic-Audio 在三种输入配置上均由联合适配获益。 WavLM-L 相对 T 进一步改善，降幅分别为 1.25、1.54 和 0.98 个百分点；Teffic-Audio 也在三种配置上全部改善。AASIST 在两类 OtA 改善，但 LtM 从 T 的 23.57% 升至 A+T 的 24.29%。

声学注入在适配后仍较难检测。 所有模型和设置中，LtM 的 EER 仍低于两类 OtA。即使是整体最优的 Teffic-Audio A+T，Handset 和 Speakerphone 的 EER 仍为 27.86% 和 28.26%，而 LtM 为 7.20%。额外声学路径带来的困难尚未消除。

联合适配在两种降噪状态上均有效。 三个模型在 off/on 子集上均由 A+T 优于 T。

降噪开关本身的影响会随适配变化。 Teffic-Audio 的 F 在 on 下更好，T 在 off 下更好，A+T 则接近一致，off/on 分别为 23.63% 和 23.73%。

8.3 未见路由、设备与语言

实录适配的收益延伸到未见设备与路由。 T 与 A+T 在三个模型的全部四类路由上均优于 F。WavLM-L 和 Teffic-Audio 进一步在所有路由组上由 A+T 优于 T；AASIST 在三组改善，但 Vivo 作为拨出方时从 37.54% 升至 37.86%。收益因此不仅出现在训练覆盖的 Samsung—iPhone 路由，也延伸到当前测试环中的新组合和 Vivo。这个结论限于现有设备与采集设计，不直接推广到任意硬件或通话服务。

WavLM-L 与 Teffic-Audio 在两种语言上均由联合适配获益。 两者在中英文均获得 A+T 相对 T 的改善。AASIST 的中文 EER 从 42.47% 降至 37.23%，英文却从 33.20% 升至 36.48%。其整体收益伴随语言间的不同变化。

8.4 质量层级与单个录制条件

根据每个条件的平均 DNSMOS 下降，将 42 个条件分为质量下降较小、中等和较大的三组，每组 14 个条件、7,840 条录音。所有模型使用同一套分组，分组不参考检测分数。

WavLM-L 与 Teffic-Audio 在所有质量层级上均由联合适配获益。 两者在三组上均由 A+T 优于 T；AASIST 在中等和较大下降组改善，在较小下降组回退。

适配后，质量损失更大的条件仍更难检测。 对全部模型和设置，EER 都随质量下降层级增加而升高。Teffic-Audio A+T 从较小下降组的 10.97% 升至较大下降组的 31.20%。这是一组同时包含路径、路由及降噪影响的描述性分层，不代表音质的独立因果效应。

整体改善与单个条件回退可以同时存在。 在 42 个单独条件中，A+T 相对 T 分别改善 WavLM-L 的 25 个、AASIST 的 27 个和 Teffic-Audio 的 28 个条件，回退条件数分别为 12、11 和 6，其余持平。因此，整体及大分组上的一致收益可以与局部回退同时存在。

8.5 公开测试集上的性能保持

在 ASVspoof2021 LA、ASVspoof5 和 In-the-Wild 上比较 F、A、T 与 A+T，各测试集分别计算 EER。适配模型的评测分别包含 148,176、680,774 和 31,779 条语音；ASVspoof2021 LA 仅使用 eval 划分。F 采用模型贡献者提供的 EER，A/T/A+T 从提供的逐样本分数重新计算。




图 8. 适配相对 F 的 EER 变化（百分点）。各柱表示 A、T 或 A+T 的 EER 减去同模型、同测试集的 F 结果。负值表示改善，正值表示退化；三个面板共用-4 至+4 的纵轴，虚线为 F 基线。

模拟增强的收益不限于通话域。 A 改善了三个模型在 ASVspoof2021 LA 上的性能。在 ASVspoof5 上，WavLM-L 改善 0.85 个百分点，另外两个模型变化较小。

联合适配存在跨域权衡。 A+T 改善了三个模型的通话域性能，但在 In-the-Wild 上的 EER 分别上升 0.38、0.78 和 0.85 个百分点。ASVspoof2021 LA 上，WavLM-L 基本持平，另外两个模型改善；ASVspoof5 上，AASIST 和 Teffic-Audio 出现退化。

8.6 模型对增强的响应差异

WavLM-L 与 Teffic-Audio 在主要分组上的响应更一致。 在图 7 中，A 不差于 F，A+T 优于 T。AASIST 也获得整体改善，但在英文、LtM、部分设备角色及数字域出现权衡。这些分组差异表明，整体收益不意味着所有条件都改善。

容量与预训练是可能的解释，尚未被单独验证。两者可能共同影响模型吸收复杂信道变化的能力。WavLM-L 和 Tefic-Audio 使用大型预训练编码器，AASIST 采用较紧凑的任务专用结构。但这里容量、结构和预训练同时变化，尚不能单独证明“小模型容量不足”。现有证据支持的是模型响应存在差异，而不是确定的容量机制。

9. 讨论与结论

RealComm 通过同源数字语音与真实通话录音的配对，展示了已有检测器在接收端语音上的明显退化。实验结果一致表明，外部播放与麦克风采集构成的声学注入更难检测。条件层面的质量退化与受测模型的检测退化一致对应，而单独的高频能量变化不足以解释这一排序。

模拟增强与实录训练均能带来收益，二者结合取得三个模型最低的整体通话 EER，并在当前未见设备与路由上保留改善。同时，声学注入仍有较高错误率，AASIST 的数字域和部分子集也存在回退。评估时需要同时保留整体结果、数字域参照与条件标签。

采集设计覆盖多种设备、两种语言，以及跨划分共享的七个生成器；降噪比较对应拨出方的用户可控设置。

这些结果支持结合数字参考与真实通话录音开展评测，保留条件标签，并将模拟扰动与真实通话训练结合。RealComm 为信号、检测器与适配三个层面的研究提供了配对数据和分析基础。

参考文献

- [1] J. Yi, C. Wang, J. Tao, X. Zhang, C. Y. Zhang, and Y. Zhao, “Audio Deepfake Detection: A Survey,” arXiv preprint arXiv:2308.14970, 2023. [Online]. Available: <<https://arxiv.org/abs/2308.14970>>
- [2] P. Anastassiou, J. Chen, J. Chen, Y. Chen et al., “Seed-TTS: A family of high-quality versatile speech generation models,” arXiv preprint arXiv:2406.02430, 2024. [Online]. Available: <<https://arxiv.org/abs/2406.02430>>
- [3] Z. Du, Y. Wang, Q. Chen, X. Shi, X. Lv, T. Zhao, Z. Gao, Y. Yang, C. Gao, H. Wang et al., “CosyVoice 2: Scalable streaming speech synthesis with large language models,” arXiv preprint arXiv:2412.10117, 2024. [Online]. Available: <<https://arxiv.org/abs/2412.10117>>
- [4] Y. Chen, Z. Niu, Z. Ma, K. Deng, C. Wang, J. Zhao, K. Yu, and X. Chen, “F5-TTS: A fairytale that fakes fluent and faithful speech with flow matching,” arXiv preprint arXiv:2410.06885, 2024. [Online]. Available: <<https://arxiv.org/abs/2410.06885>>
- [5] Y. Zhang, G. Zhu, F. Jiang, and Z. Duan, “An Empirical Study on Channel Effects for Synthetic Voice Spoofing Countermeasure Systems,” in Interspeech 2021, 2021, pp. 4309–4313.
- [6] M. Todisco, X. Wang, V. Vestman, M. Sahidullah, H. Delgado, A. Nautsch, J. Yamagishi, N. Evans, T. H. Kinnunen, and K. A. Lee, “ASVspoof 2019: Future Horizons in Spoofed and Fake Audio Detection,” in Interspeech 2019, 2019, pp. 1008–1012.
- [7] X. Liu, X. Wang, M. Sahidullah, J. Patino, H. Delgado, T. Kinnunen et al., “ASVspoof 2021: Towards Spoofed and Deepfake Speech Detection in the Wild,” IEEE/ACM Transactions on Audio, Speech, and Language Processing, vol. 31, pp. 2507–2522, 2023.
- [8] X. Wang, H. Delgado, H. Tak, J. weon Jung, H. jin Shim, M. Todisco et al., “ASVspoof 5: Design, collection and validation of resources for spoofing, deepfake, and adversarial attack detection using crowdsourced speech,” Computer Speech & Language, vol. 95, no. 101825, p. 101825, 2026.
- [9] X. Wang, H. Delgado, N. Evans, X. Liu, T. Kinnunen, H. Tak et al., “ASVspoof 5: Evaluation of Spoofing, Deepfake, and Adversarial Attack Detection Using Crowdsourced Speech,” arXiv preprint arXiv:2601.03944, 2026. [Online]. Available: <<https://arxiv.org/abs/2601.03944>>
- [10] J. Frank and L. Schönherr, “WaveFake: A Data Set to Facilitate Audio Deepfake Detection,” in Advances in Neural Information Processing Systems, Datasets and Benchmarks Track, 2021. [Online]. Available: <<https://arxiv.org/abs/2111.02813>>
- [11] N. M. Müller, P. Kawa, W. H. Choong, E. Casanova, E. Gölge, T. Müller et al., “MLAAD: The Multi-Language Audio Anti-Spoofing Dataset,” in International Joint Conference on Neural Networks (IJCNN), 2024. [Online]. Available: <<https://arxiv.org/abs/2401.09512>>
- [12] Y. Lu, Y. Xie, R. Fu, Z. Wen, J. Tao, Z. Wang et al., “Codecfake: An Initial Dataset for Detecting LLM-based Deepfake Audio,” in Interspeech 2024, 2024, pp. 1390–1394. [Online]. Available: <<https://arxiv.org/abs/2406.08112>>
- [13] N. Müller, P. Czempin, F. Diekmann, A. Froghyar, and K. Böttinger, “Does Audio Deepfake Detection Generalize?” in Interspeech 2022, 2022, pp. 2783–2787.
- [14] J. weon Jung, Y. Wu, X. Wang, J.-H. Kim, S. Maiti, Y. Matsunaga et al., “SpoofCeleb: Speech Deepfake Detection and SASV in the Wild,” IEEE Open Journal of Signal Processing, vol. 6, pp. 68–77, 2025.
- [15] X. Li, P.-Y. Chen, and W. Wei, “Measuring the Robustness of Audio Deepfake Detection under Real-World Corruption,” arXiv preprint arXiv:2503.17577, 2025. [Online]. Available: <<https://arxiv.org/abs/2503.17577>>
- [16] H. Shi, X. Shi, S. Dogan, S. Alzubi, T. Huang, and Y. Zhang, “Benchmarking Audio Deepfake Detection Robustness in Real-World Communication Scenarios,” in 2025 33rd European Signal Processing Conference (EUSIPCO), 2025, pp. 566–570.

- [17] J. Xue, Z. Yi, Y. Huang, Y. Ren, Y. Chen, C. Fan, Z. Su, Y. Zhang, and B. Cai, "RTCFake: Speech deepfake detection in real-time communication," in Findings of the Association for Computational Linguistics: ACL 2026, 2026, pp. 5763–5775. [Online]. Available: <<https://aclanthology.org/2026.findings-acl.285/>>
- [18] A. Tsutsumi, A. Gotoh, Y. Saito, H. Matsuura, and S. Shiota, "Domain Adaptation for Deepfake Audio Detection under Degraded Channel Conditions," in Odyssey 2026, 2026, pp. 9–14.
- [19] L. Wang, K. Mai, and Z. Wu, "RealComm: Benchmarking audio deepfake detection under real communication channels," in IEEE Spoken Language Technology Workshop (SLT), 2026, accepted for publication.
- [20] H. Tak, J. Patino, M. Todisco, A. Nautsch, N. Evans, and A. Larcher, "End-to-end anti-spoofing with RawNet2," arXiv preprint arXiv:2011.01108, 2020. [Online]. Available: <<https://arxiv.org/abs/2011.01108>>
- [21] J. weon Jung, H.-S. Heo, H. Tak, H. jin Shim, J. S. Chung, B.-J. Lee et al., "AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks," in ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2022, pp. 6367–6371.
- [22] A. Baevski, H. Zhou, A. Mohamed, and M. Auli, "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations," in Advances in Neural Information Processing Systems, 2020. [Online]. Available: <<https://arxiv.org/abs/2006.11477>>
- [23] W.-N. Hsu, B. Bolte, Y.-H. H. Tsai, K. Lakhotia, R. Salakhutdinov, and A. Mohamed, "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units," arXiv preprint arXiv:2106.07447, 2021. [Online]. Available: <<https://arxiv.org/abs/2106.07447>>
- [24] A. Babu, C. Wang, A. Tjandra, K. Lakhotia, Q. Xu, N. Goyal et al., "XLS-R: Self-supervised Cross-lingual Speech Representation Learning at Scale," arXiv preprint arXiv:2111.09296, 2021. [Online]. Available: <<https://arxiv.org/abs/2111.09296>>
- [25] S. Chen, C. Wang, Z. Chen, Y. Wu, S. Liu, Z. Chen, J. Li, N. Kanda, T. Yoshioka, X. Xiao et al., "WavLM: Large-scale self-supervised pre-training for full stack speech processing," IEEE Journal of Selected Topics in Signal Processing, vol. 16, no. 6, pp. 1505–1518, 2022. [Online]. Available: <<https://arxiv.org/abs/2110.13900>>
- [26] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust speech recognition via large-scale weak supervision," in Proceedings of the 40th International Conference on Machine Learning, ser. Proceedings of Machine Learning Research, vol. 202, 2023, pp. 28 492–28 518. [Online]. Available: <<https://proceedings.mlr.press/v202/radford23a.html>>
- [27] Seamless Communication et al., "Seamless: Multilingual expressive and streaming speech translation," arXiv preprint arXiv:2312.05187, 2023. [Online]. Available: <<https://arxiv.org/abs/2312.05187>>
- [28] H. Tak, M. Todisco, X. Wang, J. weon Jung, J. Yamagishi, and N. Evans, "Automatic Speaker Verification Spoofing and Deepfake Detection Using Wav2vec 2.0 and Data Augmentation," in The Speaker and Language Recognition Workshop (Odyssey 2022), 2022, pp. 112–119.
- [29] Q. Zhang, S. Wen, and T. Hu, "Audio deepfake detection with self-supervised XLS-R and SLS classifier," in Proceedings of the 32nd ACM International Conference on Multimedia, 2024, pp. 6765–6773. [Online]. Available: <<https://github.com/QiShanZhang/SLSforASVspoof-2021-DF>>
- [30] Speech Arena, "DF Arena 500M V1: Released antispoofing model," Model repository, 2026, accessed: Sep. 19, 2026. [Online]. Available: <https://huggingface.co/Speech-Arena-2025/DF_Arena_500M_V_1>
- [31] H. Tak, M. Kamble, J. Patino, M. Todisco, and N. Evans, "Rawboost: A Raw Data Boosting and Augmentation Method Applied to Automatic Speaker Verification Anti-Spoofing," in ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2022, pp. 6382–6386.
- [32] A. Cohen, I. Rimon, E. Aflalo, and H. H. Permuter, "A study on data augmentation in voice anti-spoofing," Speech Communication, vol. 141, pp. 56–67, 2022.
- [33] A. Défossez, J. Copet, G. Synnaeve, and Y. Adi, "High fidelity neural audio compression," Transactions on Machine Learning Research, 2023. [Online]. Available: <<https://arxiv.org/abs/2210.13438>>
- [34] ByteDance Speech, "Seed-TTS-Eval: Objective evaluation set and evaluation scripts," Software repository, accessed: Sep. 19, 2026. [Online]. Available: <<https://github.com/BytedanceSpeech/seed-tts-eval>>
- [35] C. K. A. Reddy, V. Gopal, and R. Cutler, "DNSMOS P.835: A non-intrusive perceptual objective speech quality metric to evaluate noise suppressors," in Proc. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2022. [Online]. Available: <<https://arxiv.org/abs/2110.01763>>
- [36] D. Chen, X. Zhang, Y. Wang, K. Dai, L. Ma, and Z. Wu, "FlexiVoice: Enabling Flexible Style Control in Zero-Shot TTS with Natural Language Instructions," arXiv preprint arXiv:2601.04656, 2026. [Online]. Available: <<https://arxiv.org/abs/2601.04656>>
- [37] S. Zhou, Y. Zhou, Y. He, X. Zhou, J. Wang, W. Deng et al., "IndexTTS2: A Breakthrough in Emotionally Expressive and Duration-Controlled Auto-Regressive Zero-Shot Text-to-Speech," arXiv preprint arXiv:2506.21619, 2025. [Online]. Available: <<https://arxiv.org/abs/2506.21619>>
- [38] Y. Wang, H. Zhan, L. Liu, R. Zeng, H. Guo, J. Zheng et al., "MaskGCT: Zero-Shot Text-to-Speech with Masked Generative Codec Transformer," arXiv preprint arXiv:2409.00750, 2024. [Online]. Available: <<https://arxiv.org/abs/2409.00750>>
- [39] X. Zhang, J. Zhang, Y. Wang, C. Wang, Y. Chen, D. Jia et al., "Vevo2: A Unified and Controllable Framework for Speech and Singing Voice Generation," arXiv preprint arXiv:2508.16332, 2025. [Online]. Available: <<https://arxiv.org/abs/2508.16332>>
- [40] B. Zhang, C. Guo, G. Yang, H. Yu, H. Zhang, H. Lei et al., "MiniMax-Speech: Intrinsic Zero-Shot Text-to-Speech with a Learnable Speaker Encoder," arXiv preprint arXiv:2505.07916, 2025. [Online]. Available: <<https://arxiv.org/abs/2505.07916>>
- [41] Z. Gao, S. Zhang, I. McLoughlin, and Z. Yan, "Paraformer: Fast and Accurate Parallel Transformer for Non-autoregressive End-to-End Speech Recognition," arXiv preprint arXiv:2206.08317, 2022. [Online]. Available: <<https://arxiv.org/abs/2206.08317>>
- [42] J. Hillenbrand, L. A. Getty, M. J. Clark, and K. Wheeler, "Acoustic characteristics of American English vowels," The Journal of the Acoustical Society of America, vol. 97, no. 5, pp. 3099–3111, 1995.

[43] D. Snyder, G. Chen, and D. Povey, “MUSAN: A music, speech, and noise corpus,” arXiv preprint arXiv:1510.08484, 2015. [Online]. Available: <<https://arxiv.org/abs/1510.08484>>